

Tech Challenge Fase 3 — Predição de Alfabetização Municipal

Instituição: FIAP PosTech **Curso:** AI Scientist **Aluno:** Guilherme Diniz Leocadio **Fase:** 3 — Modelagem Supervisionada **Repositório Fase 2:** <https://github.com/GuilhermeDinizLeocadio/tech-challenge-fase2>

1. Contexto e Objetivo

O **Compromisso Nacional Criança Alfabetizada** (Decreto nº 11.556/2023) estabelece a meta de que todas as crianças brasileiras estejam alfabetizadas até o final do 2º ano do ensino fundamental. Cada município tem uma **meta anual pactuada**, e monitorar quem está no caminho de cumpri-la é essencial para direcionar políticas públicas.

Este projeto constrói um **modelo supervisionado de classificação binária** que prevê se um município **atingirá ou não sua meta de alfabetização**, usando variáveis territoriais, socioeconômicas e histórico de desempenho.

Pergunta central: É possível prever, com dados disponíveis *antes* do resultado, quais municípios correm risco de não cumprir a meta — permitindo intervenção antecipada?

2. Definição do Alvo

Item	Decisão
Variável-alvo	<code>atingiu_meta_2025</code> (binária)
Classe 1	Taxa INEP 2025 $\geq$ meta pactuada 2025
Classe 0	Taxa INEP 2025 $<$ meta pactuada 2025
Grão	Um município por linha (rede pública total, <code>ID_TIPO_REDE=5</code>)
N	5.342 municípios
Balanceamento	72,8% classe 1 / 27,2% classe 0

Justificativa: o alvo se alinha diretamente à política pública (metas oficiais pactuadas). A compatibilidade entre as escalas do INEP e da Base dos Dados foi verificada empiricamente (correlação de 0,69 entre a taxa de 2024 e a de 2025).

Enquadramento temporal: o modelo é treinado com dados disponíveis até 2024 para prever o resultado de 2025, simulando a situação real de um gestor que precisa antecipar o desfecho antes de ele ocorrer.

Tratamento de Data Leakage

Foram **excluídas** da matriz de features todas as variáveis derivadas do resultado de 2025:

- `PC_ALUNO_ALFABETIZADO` (taxa 2025) — é o próprio desfecho
- `meta_alfabetizacao_2025` — é o limiar que define o alvo
- Qualquer coluna calculada a partir delas

Adicionalmente, o pré-processamento é encapsulado num `Pipeline` do Scikit-learn, de modo que imputação e padronização são **aprendidas apenas no conjunto de treino** — impedindo vazamento por construção.

3. Fontes de Dados

Fonte	Arquivo / API	Uso
INEP AEEB 2025	<code>TS_MUNICIPIO.csv</code>	Taxa 2025 → alvo
Base dos Dados	<code>meta_municipio.csv</code>	Meta 2025 → alvo
Base dos Dados	<code>municipio.csv</code>	Taxa 2023/2024 → features
IBGE (API v3)	Agregado 6579	População 2025 → feature
IBGE (API v3)	Agregado 5938	PIB 2023 → feature

A integração usa o **código IBGE de 7 dígitos** como chave. Os dados do IBGE são obtidos via API pública, sem autenticação — garantindo reprodutibilidade.

Features finais

Feature	Tipo	Descrição
<code>taxa_2023</code>	numérica	Taxa de alfabetização em 2023
<code>taxa_2024</code>	numérica	Taxa de alfabetização em 2024
<code>variacao_2023_2024</code>	numérica	Tendência (2024 – 2023)
<code>melhorou</code>	binária	Flag de melhora
<code>populacao</code>	numérica	População estimada 2025
<code>pib_per_capita</code>	numérica	PIB por habitante
<code>uf</code>	categórica	Estado (one-hot encoding)

Após o pré-processamento, a matriz resultante tem **31 colunas**.

4. Análise Exploratória (EDA)

A EDA está documentada em `notebooks/01_eda.ipynb`.

Principais observações

- **Distribuição do alvo:** desbalanceamento moderado (72,8% / 27,2%), tratável com `class_weight='balanced'` sem necessidade de oversampling.

- **Nulos:** taxa_2023 apresenta 577 valores ausentes (10,8%), tratados por imputação com a mediana dentro do Pipeline.
- **Correlações com o alvo:** a variação 2023→2024 é a mais forte (+0,363), seguida de melhorou (+0,317) e taxa_2024 (+0,209).
- **Correlação negativa inesperada:** taxa_2023 correlaciona **negativamente** com o alvo (−0,092) — municípios com taxa alta receberam metas mais ambiciosas e têm mais dificuldade de cumpri-las.

Hipóteses formuladas e seus desfechos

#	Hipótese	Status final
H1	Municípios com maior taxa em 2024 têm mais chance de atingir a meta	Confirmada (corr. +0,209)
H2	Taxa alta em 2023 indica meta mais ambiciosa e menor chance de cumprimento	Confirmada (corr. −0,092)
H3	A região/estado tem poder preditivo independente do histórico	Confirmada — uf_RS é a 2ª feature mais importante
H4	Fatores socioeconômicos explicam variância residual	Parcialmente — correlação linear fraca, mas populacao e pib_per_capita contribuem via interações não-lineares
H5	A tendência é mais preditiva que os valores absolutos	Confirmada — variacao_2023_2024 é a feature mais importante do modelo (32,2%)

A confirmação da **H5** foi o achado mais relevante da fase exploratória: a feature de tendência, criada por engenharia de atributos a partir de dados já disponíveis, mostrou-se mais preditiva que qualquer variável socioeconômica coletada externamente.

5. Estrutura do Repositório

```
tech-challenge-fase3/
├── data/
│   ├── raw/                # CSVs brutos (não versionados)
│   ├── processed/          # base_modelagem.parquet (não versionada)
│   └── notebooks/
│       ├── 01_eda.ipynb     # Análise exploratória
│       └── 02_modeling.ipynb # Modelagem, avaliação, interpretabilidade
├── src/
│   ├── preprocessing/
│   │   ├── build_base.py    # Constrói a base de modelagem
│   │   ├── enriquecer_ibge.py # Busca dados da API do IBGE
│   │   ├── pipeline.py      # ColumnTransformer + split
│   │   └── checar_correlacao.py
│   ├── modeling/
│   │   ├── train.py         # Treino, CV e otimização
│   │   └── evaluation/
│   │       ├── metrics.py    # Métricas, matriz de confusão, threshold
│   │       └── ranking_nomes.py # Ranking de municípios com nomes
│   └── visualization/
│       └── plots.py          # Geração de figuras
├── models/                  # Modelo serializado (não versionado)
├── reports/
│   ├── figures/             # Visualizações geradas
│   ├── documentacao_tecnica.pdf
│   ├── metricas_finais.json
│   └── ranking_municipios_risco.csv
├── requirements.txt
├── README.md
└── .gitignore
```

6. Como Reproduzir

```
# 1. Clone o repositório
git clone https://github.com/GuilhermeDinizLeocadio/tech-challenge-fase3
cd tech-challenge-fase3

# 2. Crie e ative o ambiente virtual
python -m venv venv
venv\Scripts\activate      # Windows
source venv/bin/activate   # Linux/Mac

# 3. Instale as dependências
pip install -r requirements.txt

# 4. Coloque os CSVs brutos em data/raw/
# (TS_MUNICIPIO.csv, meta_municipio.csv, municipio.csv)

# 5. Construa a base (inclui enriquecimento via API do IBGE)
python src/preprocessing/build_base.py

# 6. Treine o modelo
python src/modeling/train.py

# 7. Avalie o modelo
python src/evaluation/metrics.py

# 8. Gere as visualizações
python src/visualization/plots.py

# 9. Gere o ranking de municípios em risco (com nomes)
python src/evaluation/ranking_nomes.py

# Alternativamente, execute os notebooks em ordem:
# notebooks/01_eda.ipynb → notebooks/02_modeling.ipynb
```


7. Etapas do Projeto

- [x] Etapa 1 — Entendimento do problema e setup
- [x] Etapa 2 — Análise Exploratória (EDA)
- [x] Etapa 3 — Pipeline de ML (Scikit-learn)
- [x] Etapa 4 — Treinamento e validação
- [x] Etapa 5 — Avaliação e interpretabilidade
- [x] Etapa 6 — Aplicação estratégica
- [x] Etapa 7 — Entregáveis finais

8. Algoritmos Avaliados

Três algoritmos foram comparados via **validação cruzada estratificada (5-fold)** no conjunto de treino:

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regressão Logística	0,731	0,876	0,735	0,799	0,803
Random Forest	0,768	0,851	0,826	0,838	0,798
Gradient Boosting	0,784	0,811	0,917	0,861	0,808
<i>Baseline (classe majoritária)</i>	<i>0,728</i>	—	—	—	—



Modelo escolhido: Gradient Boosting — melhor F1 (equilíbrio entre precision e recall), melhor ROC-AUC e maior estabilidade entre folds (desvio-padrão de $\pm 0,010$).

Otimização de hiperparâmetros

GridSearchCV com 18 combinações $\times$ 5 folds, otimizando F1:


Model	Gradient Boosting
Score	0.861

O ganho foi marginal (F1 de 0,861 → 0,865), indicando que o teto de performance vem dos **dados**, não da configuração do modelo. Os parâmetros escolhidos são conservadores (árvores rasas, aprendizado lento), o que favorece a generalização e controla overfitting.

9. Métricas de Avaliação

Avaliação final no **conjunto de teste** (1.069 municípios nunca vistos):

Métrica	Valor
Accuracy	0,795
Precision	0,811
Recall	0,937
F1-Score	0,869
ROC-AUC	0,829
<i>Baseline</i>	<i>0,728</i>



	Prev: Não atingiu	Prev: Atingiu
Real: Não atingiu	121	170
Real: Atingiu	49	729


Desempenho por classe

Classe	Precision	Recall	F1	Suporte
Não atingiu (0)	0,71	0,42	0,52	291
Atingiu (1)	0,81	0,94	0,87	778

Achado central: o modelo é excelente em identificar municípios que **atingem** a meta (recall 0,94), mas captura apenas **42%** dos municípios que **não atingem** — justamente a classe de maior interesse para política pública. Os 170 falsos negativos da matriz de confusão representam municípios em risco real que não seriam sinalizados para intervenção.

10. Interpretação do Modelo


Feature Importance



Feature	Importância
variacao_2023_2024	32,2%
uf_RS	12,7%
populacao	11,9%
taxa_2024	11,7%
pib_per_capita	5,4%

A importância está **distribuída** entre múltiplas features — nenhuma domina isoladamente, o que corrobora a ausência de leakage.

SHAP Values



O SHAP confirma a **direção** dos efeitos:

- **Variação positiva** (município melhorando) → empurra para "atingiu"
- **Pertencer ao RS** → forte empurrão para "não atingiu"
- **Pertencer a BA ou PR** → empurra para "atingiu"
- **Taxa 2024 alta** → empurra para "atingiu"

11. Principais Insights

1. A trajetória importa mais que o patamar


A feature mais preditiva não é a taxa absoluta de alfabetização, mas a **variação entre 2023 e 2024**. Municípios em trajetória de melhora tendem a cumprir a meta independentemente de onde partiram.

2. O paradoxo das metas ambiciosas

Estados com boas taxas absolutas (Sul e Sudeste) têm **pior desempenho no cumprimento de metas** — porque suas metas pactuadas são proporcionalmente mais exigentes.

Estado	% alfabetizados 2023	% alfabetizados 2024
Alagoas	95,0%	95,0%
Amapá	95,0%	95,0%
Amazonas	95,0%	95,0%
BA	95,0%	95,0%


3. O Rio Grande do Sul é um outlier



O RS apresenta variação média de **-19,95 pontos percentuais** entre 2023 e 2024, enquanto quase todos os demais estados melhoraram. Consequentemente, **86,5% dos seus municípios** são classificados em risco, e os 20 municípios de maior risco do país são todos gaúchos.

Nota metodológica: uma queda de ~20 pp em um único ano é atípica e pode refletir mudança na metodologia de aferição do estado, não apenas piora real. Recomenda-se investigação específica antes de conclusões definitivas.

4. O limiar de decisão é uma escolha de política pública



Threshold	Recall (risco capturado)	Precision
0,30	77,3%	53,8%
0,40	57,0%	61,3%
0,50 (padrão)	41,6%	71,2%
0,60	26,5%	76,2%

Reduzir o limiar de 0,50 para 0,30 quase **dobra** a identificação de municípios em risco (42% → 77%), ao custo de mais falsos alarmes. Como o custo social de não identificar um município em risco supera o de revisar um município que estava bem, recomenda-se operar com limiar reduzido.

12. Aplicação para Políticas Públicas

Uso recomendado: o modelo deve ser empregado como **ferramenta de triagem**, não de decisão final. Ele prioriza onde a atenção do gestor deve começar, com base numa probabilidade de risco calculada por município.

Recomendações concretas:

- Priorizar municípios em trajetória de queda** — a variação anual é o sinal mais forte de risco, mais que o patamar absoluto.
- Atenção especial ao Rio Grande do Sul** — concentra os municípios de maior risco, com queda anômala que merece investigação.
- Operar com limiar reduzido (0,30)** — para maximizar a captura de municípios em risco, aceitando revisar alguns falsos positivos.

4. **Revisar a calibragem das metas** — o paradoxo identificado sugere que metas proporcionalmente mais duras para estados já bem posicionados podem desestimular em vez de impulsionar.

13. Limitações e Evoluções Futuras

Limitações

Poder preditivo modesto para a classe de risco. O recall de 0,42 na classe "não atingiu" indica que as features disponíveis não capturam bem os determinantes do fracasso. O modelo é mais confiável para confirmar sucesso que para prever fracasso.

Ausência de dados de investimento educacional. O FUNDEB seria uma feature conceitualmente ideal (é a única variável diretamente acionável por gestores), mas o valor-aluno é definido em **âmbito estadual**, tornando-o redundante com a variável `uf`. Os dados de gasto municipal efetivo (SIOPE) não possuem acesso programático reproduzível.

Ausência de IDHM. O Atlas do Desenvolvimento Humano disponibiliza download estruturado apenas do IDHM de 2010 (Censo). A versão mais recente (PNAD 2022–2024) existe, mas está restrita a portal interativo sem API. Além disso, a dimensão educação do IDHM exigiria cuidado para evitar circularidade.

Série temporal curta. Apenas três pontos no tempo (2023, 2024, 2025) limitam a modelagem de tendências mais sofisticadas.

Anomalia do RS. A queda atípica do estado pode estar distorcendo o modelo, que aprendeu "ser do RS" como forte preditor de risco.


Evoluções futuras

1. **Integrar IDHM** (dimensões renda e longevidade, evitando a dimensão educação) caso dados municipais recentes se tornem disponíveis por API.
2. **Dados de infraestrutura escolar** (Censo Escolar): número de escolas, formação docente, relação aluno/professor.
3. **Investigar a anomalia do RS** e, se confirmada como artefato metodológico, tratá-la ou excluí-la da modelagem.
4. **Ampliar a série temporal** conforme novos anos do indicador forem publicados, permitindo modelos de séries temporais.
5. **Técnicas de balanceamento** (SMOTE, undersampling) voltadas especificamente a elevar o recall da classe de risco.

Anexo — Figuras do Projeto


Este anexo reúne todas as visualizações geradas ao longo do projeto, incluindo as que não foram incorporadas ao README para mantê-lo conciso.

A.1 — Distribuições Gerais da Base




Distribuição do alvo e das taxas de alfabetização de 2023 e 2024. As taxas seguem distribuição aproximadamente normal, com deslocamento positivo de 2023 para 2024.

A.2 — Análise Regional: Meta vs Taxa Absoluta




Comparação entre o percentual de municípios que atingiram a meta e a taxa média absoluta por região. Evidencia o paradoxo: regiões com taxa alta não são necessariamente as que mais cumprem metas.

A.3 — Separação das Classes pelo Histórico




Boxplots das taxas de 2023 e 2024 por classe do alvo. A taxa de 2024 separa bem as classes; a de 2023 apresenta relação invertida, refletindo o efeito das metas mais ambiciosas.

A.4 — Matriz de Correlação




Correlações entre as variáveis numéricas e com o alvo. Confirma a correlação positiva da taxa de 2024 (+0,209) e negativa da taxa de 2023 (−0,092).

A.5 — Comparação dos Modelos




Desempenho dos três algoritmos candidatos em cinco métricas, via validação cruzada 5-fold. A linha tracejada indica o baseline.

A.6 — Feature Importance




Importância relativa das features no modelo Gradient Boosting. A distribuição equilibrada corrobora a ausência de data leakage.

A.7 — SHAP Summary Plot




Impacto e direção de cada feature na previsão. Pontos à direita empurram para "atingiu a meta"; à esquerda, para "não atingiu". A cor indica o valor da feature (vermelho = alto).

A.8 — SHAP Waterfall (Explicação Individual)




Decomposição da previsão de um município específico classificado como em risco. Mostra como cada feature contribuiu para a decisão final, partindo do valor esperado médio.

A.9 — Curva Precision-Recall e Threshold




Trade-off entre *precision* e *recall* para a classe "em risco" em diferentes limiares de decisão.

A.10 — Perfil de Risco por Estado



Posicionamento dos estados segundo taxa média de 2024 (eixo X) e variação 2023→2024 (eixo Y). O tamanho da bolha representa o risco médio. O Rio Grande do Sul destaca-se como outlier.

A.11 — Matriz de Confusão



Distribuição dos acertos e erros no conjunto de teste. Os 170 falsos negativos representam municípios em risco real não sinalizados pelo modelo no limiar padrão.